

공통 전처리를 적용한 이유

본 프로젝트의 목적은 동일한 문제에 대해 여러 머신러닝 알고리즘의 성능을 비교·분석하는 것이다. 따라서 모델 간 공정한 비교를 위해 모든 모델에 동일한 전처리 과정을 적용하였다.

만약 모델마다 서로 다른 전처리를 적용할 경우, 최종 성능 차이가 알고리즘 자체의 성능 때문인지 전처리 방법의 차이 때문인지 구분하기 어려워진다. 예를 들어 한 모델은 중앙값 대체(Median Imputation)를 사용하고 다른 모델은 결측치 제거(Drop Missing Values)를 사용할 경우, 결과 차이가 모델의 특성에서 발생한 것인지 데이터 처리 방식에서 발생한 것인지 명확하게 판단하기 어렵다.

따라서 본 프로젝트에서는 다음 사항을 모든 모델에 동일하게 적용하였다.

- 동일한 데이터셋 사용
- 동일한 Data Leakage 변수 제거
- 동일한 결측치 처리 방식 적용
- 동일한 Train/Test Split 적용
- 동일한 Random Seed(random_state=42) 적용

이를 통해 모델 간 성능 차이가 데이터 처리 과정이 아닌 알고리즘의 특성에서 발생하도록 통제하였으며, 보다 객관적인 비교 및 분석이 가능하도록 하였다.

데이터 전처리

(1) Data Leakage 변수 제거

다음 변수들은 Reel 업로드 이후에 생성되는 성과 지표이므로 예측 시점에는 알 수 없는 정보라고 판단하였다.

제거한 변수:

likes
comments
shares
saves
impressions
reach
engagement_rate

이 변수들을 사용할 경우 모델이 미래 정보를 학습하는 Data Leakage 문제가 발생할 수 있으므로 제거하였다.

(2) ID 변수 제거

초기 데이터 탐색 결과 범주형 변수는 다음 두 개만 존재하였다.

reel_id
creator_id

각 변수의 고유값 개수를 확인한 결과:

```
reel_id : 100000  
creator_id : 100000
```

으로 나타났다.

즉 모든 데이터가 서로 다른 ID를 가지고 있어 예측에 유의미한 정보를 제공하지 못하는 High Cardinality 변수로 판단하였다.

또한 One-Hot Encoding 수행 시 과도한 메모리 사용으로 Colab 세션이 반복적으로 종료되는 문제가 발생하였다.

따라서:

```
reel_id  
creator_id
```

도 같이 제거하였다.

(3) 결측치 처리

수치형 변수에 대해서는 중앙값(Median)을 사용하여 결측치를 대체하였다.

```
SimpleImputer(strategy='median')
```

을 사용하였다.

(4) 범주형 변수 처리

ID 변수 제거 이후 범주형 변수는 존재하지 않았다.

```
Remaining Categorical Columns  
[]
```

따라서 One-Hot Encoding 단계는 수행하지 않았다.

(5) EDA 수정

초기에는 Correlation Heatmap을 생성하도록 구성하였으나,

- 메모리 사용량 증가
- 실행 속도 저하

문제가 발생하였다.

따라서 Histogram과 Boxplot 기반 분석만 유지하고 Heatmap은 제거하였다.

